



COMILLAS

UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Sprint 2

Grupo 05

Santiago Moreno Marín

Hugo Albert Rodríguez de Miguel

María Ascanio Morcillo

Tecnologías de Procesamiento Big Data

3º Grado en Ingeniería Matemática e Inteligencia Artificial

Índice

INTRODUCCIÓN	3
METODOLOGÍA	4
RESULTADOS	5
CONCLUSIÓN	6

Introducción


Después de la creación automatizada de carpetas con datos de **TraidingView** en **AWS S3**, hemos iniciado el Spring 2. El objetivo clave es la familiarización del equipo con **AWS Glue Data Catalog** y **AWS Glue Crawler**. Esta herramienta permite estudiar los metadatos de nuestro *bucket* de S3 sin necesidad de almacenar los datos en *databases*. Esto es una gran ventaja porque supone un ahorro exponencial de costes a la hora de hacer *queries*.

Metodología

A lo largo de toda esta práctica hemos utilizado en entorno de AWS a través de su web y Python con la librería de *boto3*.


Para familiarizarnos con los nuevos conceptos y entender bien el proceso que se nos pide implementar en Python, primero, hemos accedido a AWS, creando el *crawler* a mano entendiendo los conceptos, y realizando lo que se nos pedía desde la interfaz del portal. Desde AWS Glue hemos creado un *crawler* y le hemos asignado los permisos y requisitos de seguridad a mano a través de un rol para que solo tuviera acceso a la carpeta que queríamos, asignándole solo permisos de lectura.

A continuación, hemos accedido al tutorial de AWS Glue proporcionado en la teoría para poder implementarlo en Python de manera automatizada. En primer lugar, se crearon una sesión a través de boto3 con nuestras credenciales y un cliente de esa sesión que se conectase a *boto3*. Luego, se creaban una *database* y un *crawler* con los nombres correspondientes. Por último, se inicializaba el *crawler* correspondiente al *bucket* de S3 de *tradingviewdata* para crear una tabla con sus metadatos (el tipo de dato en cada columna, el nombre de las columnas...).



Resultados


A continuación se muestran los resultados obtenidos a través de Python desde la interfaz de AWS. Primero fue creada la *database* y luego el *crawler*.



Databases (1)

A database is a set of associated table definitions, organized into a logical group.

Name	Description	Location URI	Created on (UTC)
trade_data_imat3a05	This database has tradingview data	-	February 11, 2025 at 18:33:25




Crawlers (1)

A crawler connects to a data store, progresses through a prioritized list of classifiers to determine the schema for your data, and then creates metadata tables in your data catalog.

Name	State	Schedule	Last run	Last run times...	Log	Table changes fr...
tradingviewdata_...	Ready		February 11, 202...		View log	1 created

Y por último el *crawler* creo la tabla correspondiente al *bucket* de S3 con su esquema que fue revisado para asegurar que los datos fuesen correctos.



Tables (1)

A table is the metadata definition that represents your data, including its schema. A table can be used as a source or target in a job definition.

Name	Database	Location	Classification	Deprecated	View data	Data quality
python_tradingviewda	trade_data_imat3a05	s3://tradingviewdata/	CSV	-	Table data	View data quality

Schema (9)

View and manage the table schema.

#	Column name	Data type	Partition key	Comment
1	symbol	string	-	-
2	open	double	-	-
3	high	double	-	-
4	low	double	-	-
5	close	double	-	-
6	volume	double	-	-
7	day	bigint	-	-
8	month	bigint	-	-
9	partition_0	string	Partition (0)	-

Conclusión

Durante este segundo sprint, implementamos con éxito las tablas de metadatos para el bucket S3 que creamos anteriormente. Esto nos permitirá realizar consultas directamente sobre los datos sin necesidad de almacenarlos en una base de datos tradicional, lo que reduciría significativamente los costes y la complejidad del sistema.

Para lograrlo, desarrollamos un script en Python que se conecta a AWS Glue, una herramienta que facilita la gestión y transformación de datos en la nube. Específicamente, configuramos un **crawler** en Glue, el cual escanea el bucket S3, extrae los metadatos de los archivos almacenados y genera automáticamente una tabla en el Data Catalog de AWS. Esta tabla servirá como referencia para futuras consultas sin necesidad de mover o duplicar los datos.

En conclusión, este sprint ha sido clave para preparar la infraestructura necesaria para el análisis de datos. Además, nos ha permitido entender mejor el ecosistema de AWS Glue y su integración con S3, lo que nos facilitará la escalabilidad y optimización del sistema en las próximas fases del proyecto.